

AI-LLM 暴露度与中国劳动力市场： 基于职业指数复现、暴露结构扩展与 CGSS 个体 证据

梁延澎

23307110174

2026 年 6 月 19 日

摘要

AI-LLM 技术暴露度¹是近年来随着大语言模型人工智能发展而被提出的概念，用来衡量不同职业的工作任务在多大程度上可能受到大语言模型技术的影响。该指标并不直接等同于职业被替代的概率，而是反映某一职业的任务内容与 LLM 在文本处理、信息整合、知识生成和规则化认知任务执行等能力之间的匹配程度。2025 年，张丹丹等基于在线招聘广告构建了中国职业层面的暴露指数。本文在此基础上展开三步分析：复现指数的分布、排序与年度趋势；从职业结构、时间动态和 K-means 聚类三方面挖掘暴露度内部结构；将暴露度匹配至 CGSS 2018、2021、2023 年个体数据，考察其与就业份额和劳动收入的关系。研究发现，暴露度高度集中于知识密集、文本处理与规则化认知任务较多的职业，职业大类能解释相当比例的差异，且 2018—2024 年中国 AI-LLM 职业暴露指数整体呈下降趋势。在 CGSS 三期数据中，未发现高暴露职业在 2023 年的就业份额稳定下降，劳动收入仅存在 Lasso-DML 下的负向边际信号且对模型设定敏感。总体看，AI-LLM 暴露度是一项有价值的职业任务画像指标，但现有证据仅属早期、探索性和相关性的劳动市场信号，不能直接解读为大语言模型已造成岗位减少或工资普遍下降。²³

¹AI-LLM 技术暴露度英文名为：AI-LLM Technology Exposure, 下文中简称为 AI-LLM 暴露度

²由于主要的基于的论文为中文论文且立足于国内的数据因此本文采用中文书写。

³由于字数限制本文正文部分相关模型等均不过于详细展开，详细介绍以及所有复现的代码可见：
<https://github.com/KouseiAimer/AI-LLM-Exposure>

1 引言与相关工作

近年来,以 ChatGPT 为代表的大语言模型人工智能技术迅速发展,使人工智能的应用场景从传统的图像识别、工业控制和算法推荐,进一步扩展到文本生成、信息整合、代码编写、客户沟通和知识服务等认知型任务 [17, 20]。与以往主要影响制造业、常规体力劳动和流程化操作的自动化技术不同,大语言模型更直接地作用于语言处理、知识生产和规则化认知任务,因此可能对会计、编辑、客服、销售、程序员等白领职业产生更为直接的影响 [16, 4, 9]。由此,如何测度不同职业受到人工智能技术影响的程度,成为理解新一轮技术变革与劳动力市场关系的重要前提。

关于技术进步与劳动力市场关系的研究,早期主要围绕技能偏向型技术进步和任务偏向型技术进步展开。Autor、Levy 和 Murnane 提出,计算机技术更容易替代可以按照明确规则执行的常规认知和常规体力任务,同时补充非常规问题解决和复杂沟通任务 [3]。这一研究推动了劳动经济学从“职业是否被技术替代”转向“职业内部哪些任务受到技术影响”的任务视角。此后,Acemoglu and Autor 进一步系统化了“技能—任务—技术”的分析框架,强调技术冲击并不是直接作用于职业整体,而是通过改变任务结构影响劳动需求、工资和就业分布 [1]。

在此基础上,技术暴露度逐渐成为衡量职业受新技术潜在影响的重要工具。Frey and Osborne 基于 ONET 职业数据库和专家判断,估算了 702 个职业被计算机化替代的概率,是自动化风险研究中的代表性文献 [14];但这类职业层面的测算容易将整个职业视为替代对象,可能忽视职业内部任务结构的差异。Arntz、Gregory 和 Zierahn 进一步从任务层面对自动化风险进行重新评估,发现若考虑同一职业内部的任务差异,自动化风险会明显低于职业层面的估计结果 [2]。随着人工智能技术的发展,相关研究开始从一般自动化风险转向人工智能暴露度测算,例如 Brynjolfsson、Mitchell 和 Rock 提出“机器学习适用性”指标,用于评估机器学习技术适合完成哪些具体工作任务 [5];Webb 利用专利文本与 ONET 职业任务描述之间的文本相似度,分别构建了职业对人工智能、软件和机器人技术的暴露度 [21];Felten、Raj 和 Seamans 则将人工智能能力与职业所需能力进行匹配,形成职业、行业和地区层面的 AI 暴露度数据 [11]。

大语言模型出现以后,技术暴露度研究进一步进入 AI-LLM 暴露度阶段。Eloundou et al. 基于人工评分和 GPT-4 评分,评估美国职业任务受到大语言模型影响的程度,发现多数劳动者的部分工作任务可能受到 LLM 技术影响 [8]。Felten、Raj 和 Seamans 也从语言模型能力出发,构建了职业和行业层面的语言模型暴露度指标 [10]。与传统自动化和机器人技术相比,大语言模型的影响对象不再主要局限于常规体力劳动或中等技能岗位,而是扩展到大量依赖文本处理、信息整合、沟通表达和知识生产的白领职业。因此,AI-LLM 暴露度研究为分析生成式人工智能对劳动市场结构的影响提供了新的工具。

在我国情境下,既有研究往往需要将我国职业与美国 SOC/O*NET 职业体系进行

匹配,再借用美国职业特征来测度中国职业的技术暴露度。然而,不同国家之间即使职业名称相近,其具体工作内容、岗位职责和劳动组织方式也可能存在差异,因此直接使用美国职业暴露度指标可能难以准确反映中国劳动力市场的实际情况 [25, 23]。张丹丹等 (2025) 基于中国在线招聘广告中的岗位描述文本,结合 O*NET 的详细工作活动和任务分类,构建了中国职业层面的大语言模型人工智能技术暴露度,并进一步分析了 AI-LLM 暴露度与职业招聘需求、薪资水平、学历要求和经验要求之间的关系。这一研究为理解大语言模型技术对中国劳动力市场的影响提供了重要基础 [24, 6]。

基于上述研究脉络,本文将 AI-LLM 技术暴露度视为衡量职业任务受大语言模型技术潜在影响程度的核心指标,并在原文研究基础上形成三层递进式分析。第一层是复现:利用“中国人工智能-大语言模型技术暴露指数数据”,检验其是否能够再现原文关于高低暴露职业分布、年度变化和职业排序的主要描述性结论。第二层是扩展:在不使用招聘广告微观数据的条件下,进一步考察暴露度自身是否存在职业结构分化、时间动态和可识别的职业类型。第三层是外接个体数据:将职业暴露度映射到 CGSS 个体样本,讨论其与职业就业份额和劳动收入之间的关系。与原文主要聚焦招聘市场需求侧不同,本文尝试把暴露度指标延伸到社会调查中的劳动者层面,并以更谨慎的方式区分“技术暴露”“劳动需求变化”和“个体收入结果”三类概念。

本文的贡献在于:区分职业暴露指数复现与招聘需求回归,避免把暴露度误当作劳动需求变量;把暴露度本身作为数据对象,使用 ANOVA、职业固定效应面板模型和 K-means 聚类刻画其结构与动态 [13, 22, 15];并将招聘市场层面的技术暴露度连接到 CGSS 个体调查数据,使研究从企业需求延伸到劳动者职业位置和收入结果。

2 AI-LLM 暴露度的深入分析

2.1 数据来源

该部分使用公开发布的“中国人工智能-大语言模型技术暴露指数数据”⁴。数据包括 SOC 职业组别、SOC 详细职业和智联二级职业三个口径,并提供基期暴露指数及 2018–2024 年动态暴露指数。基期指数主要反映 2018–2021 年综合暴露水平,年度指数用于观察不同职业暴露度随时间变化的路径。⁵

⁴由于数据获取需要一定途径,参见: <https://nsd.pku.edu.cn/xzyj/kyfb/zsfb/ai/542352.htm>

⁵详细可见:北京大学国家发展研究院 AI 与经济学实验室、智联招聘,中国“人工智能-大语言模型技术”暴露指数构建方法与数据说明, v2025.09

2.2 原文描述性结论的复现

复现结果表明,“中国人工智能-大语言模型技术暴露指数数据”能够较好支持原文关于“高暴露职业集中于白领、知识密集和规则化认知任务较多职业”的描述。SOC 职业组别中,基期暴露度最高的职业包括数学科学职业、计算机职业、金融专家、财务文员和其他教育指导及图书馆职业,暴露度分别约为 0.842、0.810、0.807、0.792 和 0.786。相反,建筑清洁和害虫控制工作人员、厨师和食品准备工作人员、水上运输工人、建筑行业工人和铁路运输工人处于低暴露端,暴露度大多低于 0.260。这一排序符合大语言模型主要处理文本、数据、知识和沟通任务的技术特征。




图 1: 基期 AI-LLM 暴露度分布




图 2: SOC 职业组别中基期暴露度最高与最低职业

2.3 职业结构分化：ANOVA 结果

为了进一步判断 AI-LLM 暴露度是否具有系统性的职业结构,本文在复现基础上使用单因子 ANOVA 进行方差分解。[13]。本文将职业大类作为分组变量,解释职业基期暴露度差异。若职业大类能够解释相当比例的方差,说明暴露度并不是少数极端职业造成的偶然排序,而是与职业任务结构高度相关。

表 1: 职业大类对 AI-LLM 暴露度差异的解释程度

职业层级	样本数	分组数	Eta squared	F 值
SOC 职业组别	60	21	0.850	11.092
SOC 详细职业	100	18	0.795	18.763
智联二级职业	100	19	0.489	4.309




图 3: 不同职业层级的暴露度方差解释比例

表 1 显示,三个职业层级的 ANOVA 均显著。SOC 职业组别中,职业大类可以解释约 85.0% 的暴露度差异;SOC 详细职业中,该比例约为 79.5%;智联二级职业中,一

级职业类别也可解释约 48.9% 的差异。图 3 进一步展示了不同职业口径下组间方差的重要性。由此可见，AI-LLM 暴露度是一种高度结构化的职业属性，高暴露主要集中于计算机与数学、商业与金融、法律、管理、办公行政、互联网产品和市场分析等职业；低暴露则更多出现在餐饮服务、清洁服务、运输搬运、建筑施工、生产制造和现场服务等职业。

2.4 时间动态：面板趋势模型

职业暴露度不是静态排名。为了考察 2018–2024 年间暴露度是否存在系统性变化，本文构造职业年度面板，并估计职业固定效应线性趋势模型。固定效应模型适合在重复观测的职业面板中控制职业层面不随时间变化的异质性，从而把识别重点放在同一职业内部的年度变化 [22]：

$$Exposure_{it} = \alpha_i + \beta Year_t + \varepsilon_{it}.$$

其中， α_i 控制职业不随时间变化的固定差异， β 衡量同一职业内部随年份变化的平均趋势。进一步地，本文加入 2023 年后阶段虚拟变量，用于观察 ChatGPT 公开发布后是否存在额外变化。

表 2: AI-LLM 暴露度年度趋势模型

职业层级	年度趋势系数	p 值	职业数
SOC 职业组别	-0.0048	0.003	60
SOC 详细职业	-0.0021	0.032	100
智联二级职业	-0.0047	< 0.001	103

结果显示，三个职业层级在控制职业固定效应后均呈现显著下降趋势。即使比较同一职业自身的年度变化，公开指数也显示 2018–2024 年间 AI-LLM 暴露度有所回落。进一步的 2023 年后阶段模型显示，SOC 详细职业的 post2023 系数为 -0.0076，p 值约为 0.047；智联二级职业的 post2023 系数为 -0.0088，p 值约为 0.096；SOC 职业组别的 post2023 系数不显著。这说明年度下降具有一定普遍性，但是否存在明显的 GPT 后额外下降仍需谨慎判断。




图 4: 2018–2024 年 AI-LLM 暴露度年度均值与离散程度

本文还估计了 β 收敛模型，即检验初始暴露度更高的职业是否下降更快。结果较弱：SOC 职业组别的初始暴露度系数为 -0.0786，但 p 值为 0.163；SOC 详细职业和智联二级职业系数接近 0。因此，结论为：AI-LLM 暴露度整体随时间回落，但不能证明初始高暴露职业显著更快下降。

2.5 职业类型：K-means 动态聚类

仅讨论“高暴露”和“低暴露”容易简化职业差异。本文进一步基于五个特征进行 K-means 聚类：基期暴露度、2018–2024 年变化、年度斜率、波动性和年度均值。K-means 的基本目标是在给定簇数下最小化簇内距离平方和，适合把多维职业特征压缩为少数可解释类型 [15]。本文使用该方法的目的是寻找因果处理组，而是把职业划分为更细致的动态暴露类型。本文根据轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数和最小簇规模逐层级选择最佳 K 。

表 3: K-means 聚类的最佳 K 与主要类型

职业层级	最佳 K	轮廓系数	主要类型
SOC 职业组别	3	0.440	低暴露稳定型；中等暴露稳定型；中等暴露急剧下降型
SOC 详细职业	2	0.445	高暴露稳定型；低暴露下降型
智联二级职业	2	0.448	高暴露稳定型；中等暴露下降型

表 3 表明，三个职业层级适合的聚类细度并不相同。SOC 职业组别由于只有 60 个左右单位，且存在一组“中等暴露急剧下降型”，最适合 $K = 3$ ；SOC 详细职业和智联二级职业则更适合 $K = 2$ 。图 5 展示了各类职业在暴露水平和变化路径上的差异。该结果说明，AI-LLM 暴露度不是一个单一静态排名，而是一组包含水平、变化和波动的

信息结构。后续接入 CGSS 时，本文选择 SOC 职业组别 $K = 3$ 作为主口径，是因为 CGSS 的 ISCO 职业编码更容易稳定映射到 SOC 职业组别，而不是智联二级职业。




图 5: 不同职业层级的 AI-LLM 暴露度动态聚类画像

综合来看，第二部分的结论为：ANOVA 说明暴露度具有职业结构分化，面板趋势模型说明暴露度存在年度动态，K-means 聚类则把这种结构和动态转化为可用于后续个体数据分析的职业画像变量。这也为第三部分把职业暴露度接入 CGSS 提供了基础。

3 CGSS 个体层面的扩展检验

3.1 数据清洗与职业映射与样本边界

第三部分使用 CGSS 2018、2021 和 2023 年数据，将职业层面的 AI-LLM 暴露度接入个体层面劳动者样本。⁶由于 CGSS 使用 ISCO-08 职业编码，而中国 AI-LLM 职业暴露指数主要基于 SOC 职业口径，本文先构造 ISCO-SOC crosswalk，再将 SOC 职业组别暴露度和 SOC K-means 类型合并到 CGSS，详细可见附录 A。⁷

3.2 就业份额：分数 Logit 与 PPML

就业结构部分以职业 g 、年份 t 为分析单位。主因变量为职业在当年有效当前职业样本中的 CGSS 加权就业份额，辅助因变量为加权就业规模。由于就业份额位于 $[0, 1]$ 区间，本文使用分数 Logit QMLE；该方法常用于处理比例型或分数型因变量 [18]。由于就业规模为非负计数型变量，辅助模型使用 PPML，并加入年度总加权就业规模 offset；PPML 在处理非负规模变量、异方差和零值时具有较好适用性 [19]。核心解释项为基础暴露度与 2021、2023 年份虚拟变量的交互项，其中 2021 项用于观察 GPT 前弱趋势，2023 项用于观察 GPT 后第一期相对变化。

⁶CGSS 数据需要登录认证后才能获取，链接为 <http://cgss.ruc.edu.cn/>

⁷除了进行 ISCO-SOC crosswalk 职业转换等，实验同时进行了相关的数据清洗等操作

表 4: AI-LLM 暴露度与 CGSS 加权就业份额

模型	变量	系数	p 值	95% 置信区间
分数 Logit	基础暴露度 $\times$ 2021	-0.967	0.461	[-3.538, 1.603]
分数 Logit	基础暴露度 $\times$ 2023	0.814	0.771	[-4.665, 6.292]
PPML	基础暴露度 $\times$ 2021	-0.930	0.463	[-3.412, 1.552]
PPML	基础暴露度 $\times$ 2023	0.780	0.776	[-4.587, 6.147]

表 4 显示，基础暴露度与 2023 年份的交互项在分数 Logit 和 PPML 中均不显著，且系数为正。由此，本文没有发现高基础暴露职业在 2023 年 CGSS 加权就业份额显著下降的稳定证据。该结论不能被理解为“AI 不影响就业”，而应理解为在现有三期 CGSS 截面、抽样权重和职业映射条件下，尚不足以支持“高暴露职业份额下降”的经验判断。




图 6: 连续处理事件研究中的就业份额系数




图 7: SOC K-means 类型的 CGSS 加权就业份额变化

进一步从 SOC K-means 类型看，中等暴露急剧下降型的归一化加权就业份额由 2018 年的 0.0893 下降至 2023 年的 0.0264，变化为 -0.0629；低暴露稳定型也由 0.3097 下降至 0.2220；相反，中等暴露稳定型由 0.6009 上升至 0.7516。图 7 显示，不同动态暴露类型的就业结构变化并不符合简单的“高暴露必然收缩”叙事。K-means 类型更适合描述职业结构重组，而不宜单独作为 AI 替代劳动的因果证据。

3.3 劳动收入：加权 DML

工资收入部分以个体为分析单位，因变量为劳动收入的对数形式。本文采用 Double/Debiased Machine Learning。DML 的优势在于可以使用机器学习模型刻画高维控制变量与因变量、处理变量之间的非线性关系，并通过交叉拟合降低过拟合造成的偏误 [7]。模型的控制变量包括年龄、年龄平方、性别、教育、城乡、健康、婚姻、省份、年

份、4 位 ISCO 职业、ISCO 职业大类、映射质量变量、基础暴露度主效应、暴露度动态变量和 SOC K-means 类型。模型使用 CGSS 调查权重，并按 4 位 ISCO 职业聚类计算标准误。

表 5: AI-LLM 暴露度与劳动收入：DML 结果

学习器	处理变量	系数	职业聚类标准误	p 值	95% 置信区间
Lasso-DML	基础暴露度 $\times$ 2023 调查	-0.666	0.385	0.084	[-1.420, 0.089]
Lasso-DML	高暴露四分位 $\times$ 2023 调查	-0.287	0.164	0.079	[-0.608, 0.033]
GBRT-DML	基础暴露度 $\times$ 2023 调查	-1.620	4.237	0.702	[-9.924, 6.684]
GBRT-DML	高暴露四分位 $\times$ 2023 调查	-14.856	10.407	0.153	[-35.254, 5.542]

表 5 显示，Lasso-DML 中基础暴露度与 2023 调查交互项为 -0.666，p 值为 0.084；高暴露四分位与 2023 调查交互项为 -0.287，p 值为 0.079。二者均表现出 10% 水平附近的负向边际信号。然而，GBRT-DML 敏感性结果并不显著，且置信区间很宽。因此，最终结果能把该结果解释为高暴露职业劳动收入可能存在早期负向信号，而不能作为稳定工资下降证据，进一步不能将其解释为强因果效应。




图 8: DML 模型中的劳动收入效应估计




图 9: RIF 回归中的劳动收入分位点效应

3.4 收入分布：RIF 回归

均值模型可能掩盖收入分布内部差异。我们进一步使用加权 RIF 回归考察 AI-LLM 暴露度与劳动收入第 25、50 和 75 分位之间的关系。RIF 回归估计的是无条件分位点关系，适合回答“AI-LLM 暴露度是否主要影响低收入、中位收入或高收入劳动者”这一问题 [12]。

表 6: 基础暴露度与劳动收入分位点: RIF 结果

分位点	系数	p 值	95% 置信区间
第 25 分位	-0.434	0.275	[-1.214, 0.345]
第 50 分位	-0.060	0.869	[-0.775, 0.654]
第 75 分位	-0.511	0.068	[-1.058, 0.037]

RIF 结果未显示基础暴露度在不同收入分位上存在一致稳定关系。第 75 分位出现 10% 水平附近的负向边际信号, 但第 25 分位和中位数并不显著, 高暴露四分位项也不显著。因此, 目前不能认为 AI-LLM 暴露度已经明显改变 CGSS 劳动收入分布。该结果与 DML 均值模型相互呼应: 收入方面存在值得继续跟踪的负向线索, 但现有证据仍较弱。

4 结论

综合复现、基础扩展和 CGSS 个体层面分析, 本文得到以下相关主要结论。这些结论共同说明, AI-LLM 暴露度既可以作为职业任务结构的测度, 也可以作为连接招聘市场和个体调查数据的中介变量。

其一, **AI-LLM 暴露度具有明确的职业任务含义**。复现结果显示, 高暴露职业主要集中在数学科学、计算机、金融、财务、教育指导、数据工程、产品经理、市场调研和专业分析等领域。这些职业共同特点是依赖文本处理、信息整合、规则化判断、知识生成和沟通表达。低暴露职业则更多涉及现场移动、体力操作、设备使用、清洁服务、餐饮制作和运输搬运。由此可见, **AI-LLM 暴露度并不是抽象的技术标签, 而是与职业任务结构紧密相关的指标**。

其二, **AI-LLM 暴露度自身具有结构分化和动态演化特征**。ANOVA 显示, 职业大类能够解释 SOC 职业组别 85.0% 的暴露度差异和 SOC 详细职业 79.5% 的差异。面板趋势模型显示, 2018–2024 年三个职业层级的中国 AI-LLM 职业暴露指数均存在显著下降趋势, 但没有发现稳健的 β 收敛证据。K-means 聚类进一步说明, 不同职业层级适合不同聚类细度, SOC 职业组别为 $K = 3$, SOC 详细职业和智联二级职业为 $K = 2$ 。这意味着暴露度不应仅被用作静态排序, 而可以被扩展为包含水平、变化和波动的职业画像。

其三, **CGSS 数据未支持“高暴露职业就业份额显著下降”的稳定结论**。分数 Logit 和 PPML 模型中, 基础暴露度与 2023 调查年份的交互项均不显著, 且置信区间较宽。SOC K-means 类型显示部分动态类型的就业份额下降, 但低暴露稳定型同样下降, 而

中等暴露稳定型上升，说明就业结构变化并不符合单向替代叙事。考虑到 CGSS 是抽样调查，本文也不把样本职业人数解释为全国真实职业人数，而只讨论加权就业份额。

其四，**劳动收入方面存在弱负向信号，但证据尚不稳健**。Lasso-DML 显示高暴露职业在调查对应的 2023 年劳动收入中可能存在负向边际关系，但 GBRT-DML 不支持稳定显著性，RIF 回归也未发现第 25、50、75 分位上的一致效应。由于我们仅仅有初期的数据，因而这一结果最多反映 GPT 出现前后极早期的关联信号，不能解释为完整的 GPT 后长期工资效应。

5 讨论

本文最重要的讨论是：**AI-LLM 暴露度不等于替代概率**。高暴露表示一个职业的任务内容与大语言模型能力之间存在较强重合，但这种重合可能导向替代，也可能导向互补。对于某些规则化文本处理任务，企业可能减少人工需求；对于需要沟通、判断、协调和责任承担的职业，AI-LLM 也可能成为提高效率的辅助工具。因此，将暴露度直接解释为“失业风险”或“工资下降概率”会过度简化技术与劳动之间的关系。

原文招聘市场证据与本文 CGSS 证据对应的是劳动市场的不同侧面。招聘广告更接近企业新增岗位需求，CGSS 更接近劳动者存量就业和收入结果。因此，本文没有发现 CGSS 加权就业份额显著下降，并不必然否定招聘市场中高暴露岗位需求相对回落的结论。更合理的解释是：招聘需求变化可能先于存量就业结构变化出现，而个体收入结果需要更长时间才能在调查数据中稳定体现。

此外，职业映射是不确定性的主要来源。中国 AI-LLM 职业暴露指数使用 SOC 和智联职业口径，而 CGSS 使用 ISCO-08 职业编码。虽然本文通过 crosswalk 和前缀回退尽量提高匹配率，但不同职业分类体系之间并不存在完全一一对应关系。尤其在个体层面，职业信息缺失、非就业状态和粗粒度职业编码都会降低可匹配样本比例。因此，CGSS 结果应被理解为职业暴露度外接个体调查数据的一次尝试，而不是最终识别。

最后，当前样本期对 GPT 后效应的观察仍然较短。CGSS 2023 年调查收入对应 2023 年收入，而 ChatGPT 直到 2022 年 11 月底才公开发布。即便企业或劳动者迅速采用大语言模型，相关影响也可能更多体现在 2023 年以后收入、职业转换和工作任务调整中。因此，本报告关于收入下降的结论必须保持保守。未来若能获得 2025 年以后 CGSS 或其他个体追踪数据，将更适合检验 GPT 后中期影响。

6 未来工作

未来研究可以考虑从以下方面进行进一步的扩展与说明：

- 由于我们现在仅能获取 CGSS 截至 2023 年的数据，从而相关结论不太显著，进一步我们可以补充更多年份的 CGSS、职业就业统计或招聘广告微观数据。再依照数据展开更详细地分析。
- 由于国际之间的职业并没有完美匹配，因此我们可以考虑改进 ISCO-SOC 映射，结合职业名称、任务描述、行业信息和人工校验降低职业错配。
- 我们可进一步考虑：代效应与互补效应。进一步可以考虑引入 AI 互补性、数字技能要求和组织采用程度等变量进行辅助解释说明。
- 我们可扩展个体结果变量，继续考察就业状态、职业转换、工作时间、培训参与和数字技能使用等结果从而可以使得某些职业的 AI-LLM 暴露度得以改进等。

参考文献

- [1] Daron Acemoglu and David Autor. Skills, tasks and technologies: Implications for employment and earnings. In *Handbook of labor economics*, volume 4, pages 1043–1171. Elsevier, 2011.
- [2] Melanie Arntz, Terry Gregory, and Ulrich Zierahn. The risk of automation for jobs in oecd countries: A comparative analysis. *OECD social, employment and migration working papers*, 2016, 2016.
- [3] David H Autor, Frank Levy, and Richard J Murnane. The skill content of recent technological change: An empirical exploration. *The Quarterly journal of economics*, 118(4):1279–1333, 2003.
- [4] Erik Brynjolfsson, Danielle Li, and Lindsey Raymond. Generative ai at work, 2024.
- [5] Erik Brynjolfsson, Tom Mitchell, and Daniel Rock. What can machines learn and what does it mean for occupations and the economy? In *AEA papers and proceedings*, volume 108, pages 43–47. American Economic Association 2014 Broadway, Suite 305, Nashville, TN 37203, 2018.
- [6] Qin Chen, Jinfeng Ge, Huaqing Xie, Xingcheng Xu, and Yanqing Yang. Large language models at work in china’ s labor market. *arxiv*, 2023.
- [7] Victor Chernozhukov, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins. Double/debiased machine learning for treatment and structural parameters, 2018.
- [8] Tyna Eloundou, Sam Manning, Pamela Mishkin, and Daniel Rock. Gpts are gpts: Labor market impact potential of llms. *Science*, 384(6702):1306–1308, 2024.
- [9] OpenAI et. al. Gpt-4 technical report, 2024.
- [10] Ed Felten, Manav Raj, and Robert Seamans. How will language modelers like chatgpt affect occupations and industries? *arXiv preprint arXiv:2303.01157*, 2023.
- [11] Edward Felten, Manav Raj, and Robert Seamans. Occupational, industry, and geographic exposure to artificial intelligence: A novel dataset and its potential uses. *Strategic management journal*, 42(12):2195–2217, 2021.

- [12] Sergio Firpo, Nicole M Fortin, and Thomas Lemieux. Unconditional quantile regressions. *Econometrica*, 77(3):953–973, 2009.
- [13] Ronald Aylmer Fisher. Statistical methods for research workers. In *Breakthroughs in statistics: Methodology and distribution*, pages 66–70. Springer, 1970.
- [14] Carl Benedikt Frey and Michael A Osborne. The future of employment: How susceptible are jobs to computerisation? *Technological forecasting and social change*, 114:254–280, 2017.
- [15] J MacQueen. Multivariate observations. In *Proceedings of the 5th Berkeley symposium on mathematical statistics and probability*, volume 1, pages 281–297. University of California press Oakland, CA, USA, 1967.
- [16] Shakked Noy and Whitney Zhang. Experimental evidence on the productivity effects of generative artificial intelligence. *Science*, 381(6654):187–192, 2023.
- [17] Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback, 2022.
- [18] Leslie E Papke and Jeffrey M Wooldridge. Econometric methods for fractional response variables with an application to 401 (k) plan participation rates. *Journal of applied econometrics*, 11(6):619–632, 1996.
- [19] JMC Santos Silva and Silvana Tenreiro. The log of gravity. *The Review of Economics and statistics*, pages 641–658, 2006.
- [20] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [21] Michael Webb. The impact of artificial intelligence on the labor market. *Available at SSRN 3482150*, 2019.

- [22] Jeffrey M Wooldridge. *Econometric analysis of cross section and panel data*. MIT press, 2010.
- [23] 周广肃, 李力行, and 孟岭生. 智能化对中国劳动力市场的影响——基于就业广度和强度的分析. *金融研究*, 492(6):39–58, 2021.
- [24] 张丹丹, 于航, 李力行, 胡佳胤, and 莫怡青. 中国人工智能技术暴露度的测算及其对劳动需求的影响——基于大语言模型的新证据. *管理世界*, 41(7):59–75, 2025.
- [25] 王林辉, 胡晟明, and 董直庆. 人工智能技术, 任务属性与职业可替代风险: 来自微观层面的经验证据. *管理世界*, 2022.

以下为附录：

A ISCO-SOC crosswalk

映射规则为：优先使用 4 位 ISCO 精确映射；若无法精确匹配，则依次使用 3 位、2 位和 1 位 ISCO 前缀回退；若一个 ISCO 对应多个 SOC 类型，则按映射频次选择主要 SOC 类型，并保留映射来源和匹配占比以便审查。

清洗后的个体层面数据共有 32261 条记录，职业-年份面板共有 840 个职业-年份单元。个体样本中可接入 SOC K-means 类型的记录为 12345 条，匹配率为 0.383；职业-年份面板中可接入 SOC K-means 类型的单元为 831 个，匹配率为 0.989。个体层面匹配率较低，并不完全意味着 crosswalk 失败，部分原因是个体缺少当前职业、处于非就业状态，或职业信息无法稳定映射。因此，本文在解释个体结果时始终强调职业映射不确定性。

B 复现实验详细细节

B.1 数据口径与样本构成

本文使用三类数据。第一类是“中国人工智能-大语言模型技术暴露指数数据”，包含 SOC 职业组别、SOC 详细职业和智联二级职业三个职业口径的基期暴露指数及 2018–2024 年年度暴露指数。第二类是中国综合社会调查（CGSS）2018、2021 和 2023 年数据，用于构造个体层面的劳动收入、人口学特征、城乡、教育、健康、婚姻、地区和职业变量。第三类是 ISCO-08 与 SOC 职业之间的 crosswalk，用于把 CGSS 的 ISCO-08 职业编码映射到 SOC 职业口径。

表 7: 主要数据及其用途

数据名称	主要变量	在本文中的用途
中国 AI-LLM 暴露指数	基期暴露度、年度暴露度、职业口径	复现职业暴露排序并构造职业画像
CGSS 2018/2021/2023	收入、职业、教育、年龄、地区等	分析个体层面就业份额与收入关系
ISCO-08-SOC crosswalk	ISCO 与 SOC 对应关系	将 CGSS 职业接入 SOC 暴露度

在中国 AI-LLM 职业暴露指数中，基期 SOC 职业组别有 60 个，SOC 详细职业有

100 个，智联二级职业有 100 个。年度动态指数中，SOC 职业组别共有 406 个职业-年份观测，SOC 详细职业有 696 个职业-年份观测，智联二级职业有 682 个职业-年份观测。CGSS 清洗后的个体样本为 32261 条；在可接入 SOC K-means 类型的个体样本中，共有 12345 条记录，个体层面匹配率为 0.383；职业-年份面板共有 840 个单元，其中 831 个可接入 SOC K-means 类型，匹配率为 0.989。

B.2 中国 AI-LLM 职业暴露指数的复现结果

表 8 展示 SOC 职业组别中基期暴露度最高和最低的代表性职业。高暴露端集中于数学科学、计算机、金融、财务和教育图书馆相关职业，低暴露端集中于清洁、餐饮、运输、建筑和铁路运输等现场操作职业。

表 8: SOC 职业组别基期暴露度的高低端职业

类型	职业	暴露度
高暴露	数学科学职业	0.842
高暴露	计算机职业	0.810
高暴露	金融专家	0.807
高暴露	财务文员	0.792
高暴露	其他教育指导和图书馆职业	0.786
低暴露	建筑清洁和害虫控制工作人员	0.174
低暴露	厨师和食品准备工作人员	0.174
低暴露	水上运输工人	0.182
低暴露	建筑行业工人	0.220
低暴露	铁路运输工人	0.253

年度均值方面，SOC 职业组别的非加权平均暴露度从 2018 年的 0.551 降至 2024 年的 0.526，SOC 详细职业从 0.648 降至 0.634，智联二级职业从 0.660 降至 0.627。该结果说明职业暴露指数本身存在年度回落，但由于这里没有使用招聘岗位数量作为权重，因此不能把该趋势解释为市场劳动需求下降。

B.3 基础扩展模型的补充结果

职业结构分化模型使用：

$$Exposure_i = \alpha + Group_i + \varepsilon_i.$$

其中, $Exposure_i$ 为职业基期 AI-LLM 暴露度, $Group_i$ 为职业大类或一级职业类别。ANOVA 结果显示, SOC 职业组别、SOC 详细职业和智联二级职业的组间差异均显著, Eta squared 分别为 0.850、0.795 和 0.489。

年度动态模型使用:

$$Exposure_{it} = \alpha_i + \beta Year_t + \varepsilon_{it}.$$

其中, α_i 为职业固定效应。结果显示, SOC 职业组别、SOC 详细职业和智联二级职业的年度趋势系数分别为 -0.0048、-0.0021 和 -0.0047, p 值分别为 0.003、0.032 和小于 0.001。该结果支持“中国 AI-LLM 职业暴露指数在 2018–2024 年间整体下降”的描述性结论。进一步的 β 收敛检验并不显著, 因此不能认为初始高暴露职业下降更快。

表 9: K-means 动态职业类型的中心特征

职业层级	类型	基期暴露度	2018–2024 变化	年度斜率	职业数
SOC 职业组别	低暴露稳定型	0.343	0.007	-0.0003	19
SOC 职业组别	中等暴露稳定型	0.691	-0.019	-0.0034	30
SOC 职业组别	中等暴露急剧下降型	0.510	-0.182	-0.0272	7
SOC 详细职业	高暴露稳定型	0.721	0.002	0.0002	74
SOC 详细职业	低暴露下降型	0.418	-0.058	-0.0089	25
智联二级职业	中等暴露下降型	0.481	-0.093	-0.0152	26
智联二级职业	高暴露稳定型	0.725	-0.001	-0.0004	63

K-means 结果显示, 不同职业层级适合不同聚类数。SOC 职业组别的最佳 $K = 3$, SOC 详细职业和智联二级职业的最佳 $K = 2$ 。因此, 本文在 CGSS 分析中使用 SOC 职业组别 $K = 3$ 作为职业类型主口径, 主要原因是该口径与 CGSS 的 ISCO 职业映射更稳定。

B.4 就业收入模型结果

就业份额模型为:

$$\text{logit}\{E(Share_{gt})\} = \alpha_g + \lambda_t + \beta Exposure_g \times I(t = 2023) + \gamma X_{gt}.$$

辅助 PPML 模型以加权就业规模为因变量, 并加入年度总加权就业规模作为 offset。分数 Logit 中, 基础暴露度与 2023 年份的交互项系数为 0.814, p 值为 0.771; PPML 中对应系数为 0.780, p 值为 0.776。二者均不支持“高基础暴露职业在 2023 年就业份额显著下降”的结论。

劳动收入 DML 模型为：

$$Y_i = \theta T_i + f(X_i) + \varepsilon_i, \quad T_i = m(X_i) + v_i.$$

其中， Y_i 为劳动收入对数， T_i 为 AI-LLM 暴露度与 2023 调查年份的交互项， X_i 包括人口学变量、地区变量、年份变量、职业控制、暴露动态变量和映射质量变量。Lasso-DML 中，基础暴露度与 2023 调查的交互项系数为 -0.666，p 值为 0.084；高暴露四分位与 2023 调查的交互项系数为 -0.287，p 值为 0.079。GBRT-DML 对应结果不显著。因此，工资部分仅能表述为弱负向信号，不能表述为稳定工资下降证据。

RIF 分位数结果为：

$$RIF(Y_i, q_\tau) = q_\tau + \frac{\tau - I(Y_i \leq q_\tau)}{f_Y(q_\tau)}.$$

基础暴露度与 2023 调查交互项在第 25 分位的系数为 -0.434，p 值为 0.275；在第 50 分位的系数为 -0.060，p 值为 0.869；在第 75 分位的系数为 -0.511，p 值为 0.068。该结果没有显示 AI-LLM 暴露度对收入分布存在一致稳定影响。

C 最后说明

上面的附录仅简要展示模型等结果，更详细的结果可见 Github 仓库中的：

《附录：AI-LLM 暴露度实验流程与模型设定》

文档