

技术附录：AI-LLM 暴露度实验流程、模型设定与审查说明

社会科学数据挖掘课程报告补充材料

2026 年 6 月

1 附录目的与整体识别边界

本技术附录用于补充主报告中未展开的实验流程、变量构造和模型设定。主报告侧重研究问题、主要结果和结论边界；本附录侧重说明每一部分实验如何构造、为什么采用相应模型、关键参数如何设定，以及如何避免把描述性暴露指标误解释为强因果效应。

本文的核心对象是 AI-LLM 职业暴露度。暴露度衡量职业任务与大语言模型能力之间的潜在重合程度，并不等同于职业被替代概率。由此，全文识别边界为：职业暴露指数部分是描述性和结构性分析；CGSS 部分是职业暴露度与个体收入、职业就业份额之间的相关性或弱准实验信号；除非具备更强外生冲击、更多年份面板或可信工具变量，否则不把结果表述为大语言模型已经造成就业减少或工资下降。

2 数据口径与分析单元

2.1 数据名称与用途

本文使用三类数据。第一类为“中国人工智能-大语言模型技术暴露指数数据”，包含 SOC 职业组别、SOC 详细职业和智联二级职业三个口径的基期暴露度与 2018-2024 年年度暴露度。第二类为中国综合社会调查（CGSS）2018、2021 和 2023 年数据，用于获得个体劳动收入、教育、年龄、性别、城乡、健康、婚姻、地区和职业编码。第三类为 ISCO-08-SOC crosswalk，用于把 CGSS 的 ISCO-08 职业编码映射到 SOC 职业体系。

表 1：数据、分析单元与主要用途

数据名称	分析单元	主要用途
中国 AI-LLM 暴露指数	职业、职业-年份	复现职业暴露排序，构造暴露动态和职业类型
CGSS 2018/2021/2023	个体、职业-年份	研究加权就业份额和劳动收入
ISCO-08-SOC crosswalk	职业编码对应关系	将 CGSS 职业映射到 SOC 暴露度

职业暴露指数的基期样本包括 60 个 SOC 职业组别、100 个 SOC 详细职业和 100 个智联二级职业。年度动态指数包括 406 个 SOC 职业组别-年份观测、696 个 SOC 详细职业-年份观测和 682 个智联二级职业-年份观测。CGSS 清洗后的个体样本为 32261 条；职业-年份面板为 840 个单元。

2.2 核心变量

暴露度变量包括四类。第一是基期暴露度，用于衡量 2018–2021 年综合暴露水平。第二是年度暴露度，用于分析 2018–2024 年的变化。第三是暴露动态变量，包括 2018–2024 年变化量、年度斜率、年度均值和波动性。第四是分组变量，包括暴露度四分位、高暴露四分位虚拟变量和 K-means 动态职业类型。

CGSS 个体层面的主要因变量为劳动收入对数，即 $\log(\text{labor income} + 1)$ ；辅助因变量为总收入对数。职业–年份层面的就业结构因变量为 CGSS 加权就业份额和加权就业规模。控制变量包括年龄、年龄平方、性别、教育、城乡、健康、婚姻、省份、年份、ISCO 职业大类、4 位 ISCO 职业编码和职业映射质量变量。

2.3 变量字典与口径说明

为了保证复现、基础扩展和 CGSS 扩展之间的口径一致，本文将核心变量分为暴露度变量、劳动市场结果变量、个体控制变量和映射质量变量四类。表 2 给出本文实际使用的主要变量及其解释。该表的目的是不是罗列原始问卷中的全部变量，而是说明最终进入模型的变量如何被理解。

表 2：核心变量字典与使用口径

变量类别	变量名称	使用口径与解释
暴露水平	基期 AI-LLM 暴露度	反映职业在基期的平均暴露水平，主要用于职业排序、四分位分组、DML 连续处理变量和就业份额事件研究。
暴露水平	年度 AI-LLM 暴露度	2018–2024 年职业年度暴露度，用于观察暴露指数随时间变化，而不是直接解释就业或工资变化。
暴露动态	2018–2024 年变化量	以末期暴露度减去初期暴露度构造，用于判断职业暴露度是上升、稳定还是下降。
暴露动态	年度斜率	在职业内部用年度暴露度对年份回归得到的斜率，刻画暴露度的线性变化速度。
暴露动态	波动性	年度暴露度的标准差，刻画同一职业暴露指数在 2018–2024 年间是否稳定。
暴露分组	高暴露四分位	将基期暴露度位于最高四分位的职业定义为高暴露职业，用于稳健性检验。
暴露分组	K-means 职业类型	基于暴露水平、变化量、斜率、均值和波动性聚类形成的职业类型，只作为结构性分组，不作为外生处理。

变量类别	变量名称	使用口径与解释
就业结果	加权就业份额	职业-年份加权就业规模占当年总加权就业规模的比例，只能解释为 CGSS 调查中的职业结构份额。
就业结果	加权就业规模	职业-年份内样本权重的加总，用于 PPML 计数模型，并加入年度总规模 offset。
收入结果	劳动收入对数	$\log(\text{labor income} + 1)$ ，用于降低收入偏态和零收入对估计的影响。
收入结果	总收入对数	$\log(\text{total income} + 1)$ ，作为劳动收入口径的稳健性补充。
个体控制	人口学变量	年龄、年龄平方、性别、婚姻、健康、城乡、教育和省份，用于控制个体可观测差异。
职业控制	职业固定效应或职业大类	在不同模型中使用职业固定效应、ISCO 大类或 4 位 ISCO 聚类标准误，降低职业结构差异造成的混淆。
映射质量	ISCO-SOC 映射层级	记录职业映射来自 4 位精确匹配还是 3 位、2 位、1 位前缀回退，用于审查映射不确定性。

需要特别强调的是，暴露度变量是职业任务属性变量，而不是个体是否实际使用 AI 的行为变量。因此，在 CGSS 个体模型中，本文解释的是“处于更高 AI-LLM 暴露职业中的劳动者是否呈现不同收入结果”，而不是“个体使用 AI 是否导致工资变化”。这一点构成了全文最重要的解释边界。

3 实验一：公开职业暴露指数复现

3.1 目标与可复现边界

复现实验的目标是验证“中国人工智能-大语言模型技术暴露指数数据”能否再现原文中关于职业暴露分布、职业排序和年度趋势的描述性结论。由于该数据不包含招聘广告数量、岗位薪资、学历要求、经验要求、城市信息和工具变量，因此不能复现原文中关于劳动需求和薪资变化的回归表。复现实验只回答由职业指数本身能够回答的问题。

3.2 处理流程

复现实验首先读取三个职业口径的基期暴露指数和年度动态指数，并统一变量名称和职业口径。其次，对每个职业口径计算暴露度均值、标准差、分位数和极值。再次，按照基期暴露度排

序，识别高暴露和低暴露职业。最后，对 2018–2024 年年度指数计算非加权均值，用于观察职业指数本身是否存在年度变化。

表 3: 复现实验中的关键样本规模

职业口径	基期职业数	年度职业–年份观测数
SOC 职业组别	60	406
SOC 详细职业	100	696
智联二级职业	100	682

复现实验得到的主要结果是：SOC 职业组别中，数学科学职业、计算机职业、金融专家、财务文员和其他教育指导及图书馆职业位于高暴露端；建筑清洁、餐饮准备、水上运输、建筑行业和铁路运输等职业位于低暴露端。年度均值方面，SOC 职业组别从 2018 年 0.551 降至 2024 年 0.526，SOC 详细职业从 0.648 降至 0.634，智联二级职业从 0.660 降至 0.627。该结果说明职业暴露指数自身呈现回落，但不等同于招聘需求下降。

3.3 复现质量审查

复现部分的审查重点是防止把“指数复现”误写为“完整论文回归复现”。由于原文关于招聘需求、薪资、学历和经验要求的结论依赖岗位广告微观数据，而本文可得数据主要是已经构造好的职业暴露指数，因此复现范围必须限定在职业暴露度分布、排序、动态趋势和职业类型识别上。具体审查规则见表 4。

表 4: 复现实验的质量审查规则

审查项目	实验处理	报告解释
职业口径一致性	SOC 职业组别、SOC 详细职业和智联二级职业分别处理，不把不同层级直接合并排序。	不同层级的职业颗粒度不同，结论只在相应职业口径内解释。
年度动态口径	2018–2024 年年度暴露度只用于描述指数变化。	年度暴露度下降不等同于职业就业需求下降。
原文回归边界	不使用缺失的招聘数量、岗位工资和城市层面变量虚构回归。	复现结论只覆盖可由公开暴露指数验证的部分。
图表语言规范	图表标题、坐标轴和注释使用中文，保留 SOC、CGSS、K-means 等专有名词。	保证课程报告呈现风格统一，同时避免翻译专有方法名称。
结果记录	保留样本规模、职业数和年度观测数。	方便读者判断不同层级结果是否可比较。

4 实验二：暴露度结构与动态的基础扩展

4.1 ANOVA：职业结构分化

ANOVA 用于回答“暴露度差异是否主要来自职业结构”。其基本思想是把总方差拆分为组间方差和组内方差，以检验职业大类是否能解释暴露度差异 [1]。模型为：

$$Exposure_i = \alpha + \sum_g \delta_g Group_{ig} + \varepsilon_i.$$

其中， $Exposure_i$ 为职业 i 的基期 AI-LLM 暴露度， $Group_{ig}$ 为职业大类虚拟变量。SOC 口径下使用 SOC 编码前两位构造职业大类，智联口径下使用智联一级职业类别。报告指标包括 F 值、p 值和 Eta squared。Eta squared 越高，说明职业大类对暴露度差异的解释力越强。

表 5: ANOVA 方差分解结果

职业层级	样本数	分组数	Eta squared	p 值
SOC 职业组别	60	21	0.850	< 0.001
SOC 详细职业	100	18	0.795	< 0.001
智联二级职业	100	19	0.489	< 0.001

该结果说明 AI-LLM 暴露度不是少数职业的孤立高值，而是具有明显职业结构分化。SOC 职业组别和 SOC 详细职业中，职业大类分别解释 85.0% 和 79.5% 的暴露度差异。

4.2 职业固定效应面板趋势

年度动态实验回答“同一职业的暴露度是否随时间变化”。由于每个职业在 2018–2024 年存在重复观测，本文使用职业固定效应模型控制不随时间变化的职业差异 [2]：

$$Exposure_{it} = \alpha_i + \beta YearCentered_t + \varepsilon_{it}.$$

其中， α_i 为职业固定效应， $YearCentered_t$ 为中心化年份变量。核心参数 β 表示同一职业内部年度暴露度的平均变化。为观察 2023 年后是否存在额外变化，本文还估计：

$$Exposure_{it} = \alpha_i + \beta YearCentered_t + \rho Post2023_t + \varepsilon_{it}.$$

表 6: 职业固定效应年度趋势结果

职业层级	年度趋势系数	标准误	p 值	职业数
SOC 职业组别	-0.0048	0.0016	0.003	60
SOC 详细职业	-0.0021	0.0010	0.032	100
智联二级职业	-0.0047	0.0013	< 0.001	103

结果显示，三个职业层级均存在显著下降趋势。2023 年后阶段项在 SOC 详细职业中为 -0.0076， $p=0.047$ ；在智联二级职业中为 -0.0088， $p=0.096$ ；在 SOC 职业组别中不显著。因此，稳妥结论是：公开职业暴露指数整体下降，但 GPT 后额外变化并不在所有口径上稳定显著。

4.3 Beta 收敛检验

Beta 收敛检验用于回答“初始暴露度越高的职业是否下降越快”。设 $\Delta Exposure_i$ 为 2018–2024 年变化量，模型为：

$$\Delta Exposure_i = \alpha + \theta Exposure_{i,2018} + u_i.$$

若 $\theta < 0$ 且显著，说明高初始暴露职业下降更快。结果显示，SOC 职业组别的 $\theta = -0.0786$ ，但 $p=0.163$ ；SOC 详细职业和智联二级职业的系数接近 0。因此，不能认为存在稳健 beta 收敛，只能说明平均暴露度随时间回落。

4.4 K-means 动态聚类

K-means 聚类用于把多维暴露特征转化为职业类型。本文使用五个特征：基期暴露度、2018–2024 年变化量、年度斜率、年度波动性和年度均值。K-means 目标是在给定簇数下最小化簇内平方距离 [3]：

$$\min_{\{C_k\}_{k=1}^K} \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2.$$

所有特征在聚类前标准化，以避免量纲不同导致某一变量支配距离。最佳 K 由轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数和最小簇规模共同判断。

表 7: K-means 最佳聚类数与诊断结果

职业层级	最佳 K	轮廓系数	最小簇规模	最大簇规模
SOC 职业组别	3	0.440	7	30
SOC 详细职业	2	0.445	25	74
智联二级职业	2	0.448	26	63

结果显示，不同职业层级不应机械使用同一个 K 。SOC 职业组别适合三类：低暴露稳定型、中等暴露稳定型和中等暴露急剧下降型；SOC 详细职业和智联二级职业适合两类，主要区分高暴露稳定型和下降型。

4.5 聚类特征、标签规则与画像结果

K-means 聚类前，本文要求职业同时具有基期暴露度、2018 年暴露度、2024 年暴露度以及不少于 5 年的有效年度暴露观测。该规则用于避免由少数年份插值或缺失造成的虚假动态类型。聚类过程使用标准化后的五维特征，并设置固定随机种子和多次初始化，以降低初始中心选择对结果的影响。表 8 总结了五个聚类特征的含义。

表 8: K-means 聚类特征及其作用

聚类特征	构造方式	识别含义
基期暴露度 年度均值	职业基期 AI-LLM 暴露指数 2018–2024 年年度暴露度均值	区分高暴露与低暴露职业。 衡量职业在整个观察期内的 平均暴露水平。
变化量	2024 年暴露度减 2018 年暴露 度	区分上升、稳定和下降路径。
年度斜率	职业内年度暴露度对年份的线 性斜率	刻画暴露度变化速度。
波动性	年度暴露度标准差	区分平稳变化与不稳定变化。

聚类标签不是模型直接输出，而是在聚类完成后根据簇中心命名。命名规则为：基期暴露度较高且年度均值较高的簇命名为高暴露型；基期暴露度和年度均值较低的簇命名为低暴露型；介于二者之间的簇命名为中等暴露型。若变化量和年度斜率接近零，则命名为稳定型；若变化量明显为负且斜率为负，则命名为下降型；若变化量幅度较大，例如 SOC 职业组别中变化量约为 -0.18，则命名为急剧下降型。表 9 给出最终聚类画像。

表 9: K-means 聚类画像结果

职业层级	聚类类型	职业数	基期暴露度	2018–2024 变化	年度斜率	年度波动性
SOC 职业组别	低暴露稳定型	19	0.3425	0.0075	-0.0003	0.0307
SOC 职业组别	中等暴露稳定型	30	0.6906	-0.0188	-0.0034	0.0214
SOC 职业组别	中等暴露急剧下降型	7	0.5104	-0.1825	-0.0272	0.0771
SOC 详细职业	高暴露稳定型	74	0.7211	0.0021	0.0002	0.0209
SOC 详细职业	低暴露下降型	25	0.4177	-0.0579	-0.0089	0.0354
智联二级职业	中等暴露下降型	26	0.4805	-0.0926	-0.0152	0.0467
智联二级职业	高暴露稳定型	63	0.7253	-0.0005	-0.0004	0.0203

在后续 CGSS 扩展中，本文优先使用 SOC 职业组别聚类，而不是智联二级职业聚类。原因有三点：第一，CGSS 的职业编码可以通过 ISCO–SOC crosswalk 接入 SOC 体系，映射链条较清晰；第二，SOC 职业组别的 $K = 3$ 能在样本规模和类型解释之间取得较好平衡；第三，SOC 详细职业虽能提供更细职业信息，但个体样本中的精确匹配质量更容易受到职业编码缺失和多对多映射影响。因此，SOC 职业组别聚类更适合作为 CGSS 主口径，SOC 详细职业结果更适合作为稳健性样本。

5 实验三：CGSS 职业映射与样本清洗

5.1 ISCO–SOC 映射规则

CGSS 使用 ISCO-08 职业编码，而 AI-LLM 暴露指数主要使用 SOC 职业口径。因此，CGSS 扩展实验的关键步骤是职业映射。本文采用 ISCO-08–SOC crosswalk，规则如下：第一，优先使用 4 位 ISCO 精确映射；第二，精确映射失败时依次使用 3 位、2 位和 1 位 ISCO 前缀回退；第三，若一个 ISCO 编码对应多个 SOC 类型，则按照映射频次选择主要 SOC 类型；第四，保留映射来源层级和主要类型占比，以便判断映射质量。

表 10: CGSS 与 SOC K-means 类型的匹配率

数据层级	总样本或单元数	可接入 SOC 类型数	匹配率
个体样本	32261	12345	0.383
职业-年份面板	840	831	0.989

个体样本匹配率较低，主要因为部分受访者没有当前职业、处于非就业状态或职业编码过粗；职业-年份面板匹配率较高，说明在保留有效职业单元后，SOC 类型可较充分地接入就业结构分析。

5.2 收入变量与年份口径

CGSS 收入变量通常对应上一年度收入。因此，2018 年调查对应 2017 年收入，2021 年调查对应 2020 年收入，2023 年调查对应 2022 年收入。由于 ChatGPT 于 2022 年 11 月底公开发布，2023 年调查中的收入至多反映 GPT 出现前后极早期的收入信号。本文将劳动收入处理为 $\log(\text{labor income} + 1)$ ，以降低收入偏态和零收入记录对估计的影响。

工资收入模型使用的主样本为有效劳动收入、有效职业映射和必要控制变量均不缺失的个体。DML 主模型样本量为 8195，职业聚类数为 439。样本缩小主要来自收入有效性、职业映射和控制变量完整性的共同要求。

5.3 CGSS 清洗流程

CGSS 清洗的核心不是简单删除缺失值，而是把个体问卷、职业编码、职业暴露度和调查权重统一到同一分析口径。表 11 给出本文使用的主要清洗步骤。所有步骤都围绕两个原则展开：一是保留可以解释的样本，不用无法判断含义的特殊编码进入收入或职业模型；二是保留映射质量信息，使后续稳健性分析能够区分精确匹配与前缀回退匹配。

表 11: CGSS 数据清洗与合并流程

步骤	处理方式	目的
年份合并	合并 CGSS 2018、2021、2023 三期个体样本，并保留调查年份。	构造 GPT 前后可比较的重复横截面。
收入清理	将拒答、不适用、无法回答等特殊编码处理为缺失；对有效劳动收入构造 $\log(y + 1)$ 。	避免特殊编码被误认为真实收入。
职业清理	提取当前或主要职业 ISCO-08 编码，统一为可比较的职业编码格式。	为接入 SOC 暴露度提供职业桥梁。
职业映射	使用 ISCO-08–SOC crosswalk，优先 4 位精确映射，再逐级使用 3 位、2 位、1 位前缀回退。	在尽量保留样本的同时记录映射不确定性。
暴露度合并	将 SOC 职业组别暴露水平、暴露动态和 K-means 类型接入个体样本。	形成个体层面职业暴露度变量。
权重处理	在职业–年份面板中使用 CGSS 权重计算加权就业份额和加权就业规模。	避免把未加权样本数误称为职业人数。
模型样本生成	按就业份额模型、DML 模型和 RIF 模型分别生成分析样本。	保证不同模型只使用其所需变量完整的样本。

该清洗流程带来一个重要后果：就业份额模型和个体收入模型的样本并不完全相同。就业份额模型以职业–年份为单位，强调职业结构；个体收入模型以劳动者为单位，强调同一收入模型内控制变量的完整性。因此，二者结果不应机械相互替代。就业份额模型回答“高暴露职业在调查样本中的加权份额是否相对下降”，收入模型回答“处于高暴露职业的劳动者是否呈现更低收入”。这两个问题相关，但不相同。

6 CGSS 就业份额模型

6.1 模型设定

就业份额模型以职业–年份为分析单元。主因变量是 CGSS 加权就业份额，即职业 g 在年份 t 的加权就业规模占当年有效职业样本加权总规模的比例。由于份额变量位于 $[0, 1]$ 区间，使用分数 Logit QMLE[4]：

$$\text{logit}\{E(\text{Share}_{gt}|X)\} = \alpha_g + \lambda_t + \beta_{21}\text{Exposure}_g I(t = 2021) + \beta_{23}\text{Exposure}_g I(t = 2023) + \gamma X_{gt}.$$

其中， α_g 为职业固定效应， λ_t 为年份固定效应， X_{gt} 包括职业–年份的平均年龄、大专及以上学历比例和女性比例。 β_{21} 用于弱前趋势检查， β_{23} 用于观察 2023 年相对变化。

辅助模型使用 PPML，以加权就业规模为因变量，并加入年度总加权就业规模 offset[5]：

$$E(\text{Count}_{gt}|X) = \exp\{\alpha_g + \lambda_t + \beta_{21}\text{Exposure}_g I(t = 2021) + \beta_{23}\text{Exposure}_g I(t = 2023) + \gamma X_{gt} + \log \text{Total}_t\}.$$

6.2 结果解释

表 12: 就业份额与加权就业规模模型结果

模型	变量	系数	p 值	95% 置信区间
分数 Logit	基础暴露度 × 2021	-0.967	0.461	[-3.538, 1.603]
分数 Logit	基础暴露度 × 2023	0.814	0.771	[-4.665, 6.292]
PPML	基础暴露度 × 2021	-0.930	0.463	[-3.412, 1.552]
PPML	基础暴露度 × 2023	0.780	0.776	[-4.587, 6.147]

分数 Logit 和 PPML 的 2023 交互项均不显著，且置信区间较宽。因此，本实验没有发现高基础暴露职业在 2023 年 CGSS 加权就业份额中显著下降的稳定证据。这里的“就业份额”不是全国真实职业就业人数，而是 CGSS 抽样调查加权后的职业结构指标。

7 CGSS 劳动收入模型

7.1 DML 模型设定

劳动收入模型使用 Double/Debiased Machine Learning (DML) [6]。其基本形式为：

$$Y_i = \theta T_i + g(X_i) + \varepsilon_i, \quad T_i = m(X_i) + v_i.$$

其中， Y_i 是劳动收入对数， T_i 是职业暴露度与 2023 调查年份的交互项， X_i 是控制变量。DML 的核心思想是先用机器学习方法估计 $g(X_i)$ 和 $m(X_i)$ ，再对残差化后的 Y_i 和 T_i 估计 θ ，并通过交叉拟合减少过拟合偏差。

本文设置两类处理变量：连续基础暴露度与 2023 调查交互项，以及高暴露四分位与 2023 调查交互项。主学习器为 LassoCV，用于适配高维固定效应和稀疏控制；敏感性学习器为梯度提升树，用于检验非线性学习器下结果是否稳定。标准误按 4 位 ISCO 职业聚类，避免同一职业内个体误差相关导致标准误过小。

表 13: DML 劳动收入模型核心结果

学习器	处理变量	系数	聚类标准误	p 值	95% 置信区间
Lasso-DML	基础暴露度 × 2023	-0.666	0.385	0.084	[-1.420, 0.089]
Lasso-DML	高暴露四分位 × 2023	-0.287	0.164	0.079	[-0.608, 0.033]
GBRT-DML	基础暴露度 × 2023	-1.620	4.237	0.702	[-9.924, 6.684]
GBRT-DML	高暴露四分位 × 2023	-14.856	10.407	0.153	[-35.254, 5.542]

Lasso-DML 显示负向边际信号，但 GBRT-DML 不显著，说明收入结果对学习器设定敏感。本文将其解释为高暴露职业劳动收入的早期弱信号，而不是稳定的工资下降证据。

7.2 RIF 分位数模型

为避免均值模型掩盖收入分布内部差异，本文使用 RIF 回归研究第 25、50 和 75 分位的无条件分位数关系 [7]：

$$RIF(Y_i, q_\tau) = q_\tau + \frac{\tau - I(Y_i \leq q_\tau)}{f_Y(q_\tau)}.$$

其中， q_τ 是收入分位点， $f_Y(q_\tau)$ 是分位点处密度。RIF 变量构造完成后，将其作为因变量回归于暴露度处理变量和控制变量。

表 14: RIF 分位数模型核心结果

分位点	系数	p 值	95% 置信区间
第 25 分位	-0.434	0.275	[-1.214, 0.345]
第 50 分位	-0.060	0.869	[-0.775, 0.654]
第 75 分位	-0.511	0.068	[-1.058, 0.037]

第 75 分位存在 10% 水平附近的负向边际信号，但第 25 分位和中位数均不显著。因此，本文不能认为 AI-LLM 暴露度已经稳定改变劳动收入分布。

8 稳健性、审查与报告边界

本文的审查重点包括四点。第一，职业人数表述必须谨慎：CGSS 是抽样调查，不能把样本职业人数称为全国真实职业人数，因此就业部分只使用加权就业份额或加权就业规模。第二，职业映射必须报告质量：个体层面 SOC K-means 匹配率为 0.383，职业-年份面板匹配率为 0.989，说明个体层面存在明显映射不确定性。第三，收入年份必须说明：CGSS 2023 收入对应 2022 年收入，不能代表完整 GPT 后长期影响。第四，模型解释必须区分相关、预测和因果：DML 和 RIF 提高了模型适配性，但在缺少更长面板或外生冲击时，仍不能自动转化为强因果结论。

从结果稳定性看，就业份额模型和 PPML 模型均不支持高暴露职业就业份额下降；收入模型中，Lasso-DML 有负向边际信号，但 GBRT-DML 和 RIF 分位数结果不稳定。因此，全文最终结论应保持保守：AI-LLM 暴露度是有解释力的职业任务画像变量，但现有 CGSS 证据只能提供早期和有限的劳动市场关联信号。

8.1 模型判读规则

为避免不同模型的证据强度被混同，本文采用表 15 中的判读规则。该规则也是主报告最终结论保持谨慎的原因：若一个结果只在单一学习器、单一口径或边际显著水平下出现，则只能称为弱信号；只有在模型、口径和样本替换后方向一致且统计上稳定，才可称为稳健关联。

表 15: 各模型的判读规则与本文结论

模型	若结果成立应如何解释	本文实际判读
ANOVA	若 Eta squared 较高且显著，说明职业大类能解释暴露度差异。	三个职业层级均显著，说明暴露度具有明显职业结构分化。
职业固定效应趋势	若年度趋势为负且显著，说明同一职业内部暴露度随时间下降。	三个职业层级均呈显著下降，但 GPT 后额外变化不完全稳健。
Beta 收敛	若初始暴露度系数为负且显著，说明高初始暴露职业下降更快。	系数方向不构成稳健显著证据，因此不宣称收敛。
K-means 聚类	若诊断指标支持较少且稳定的簇数，说明职业可被归纳为若干暴露动态类型。	SOC 职业组别为 $K = 3$ ，SOC 详细职业和智联二级职业为 $K = 2$ ；聚类是职业画像，不是因果处理。
分数 Logit	若 $Exposure \times 2023$ 为负且显著，同时 2021 项不显著，可解释为高暴露职业就业份额在 2023 年相对下降。	2023 交互项不显著，不支持就业份额下降结论。
PPML	若 $Exposure \times 2023$ 为负且显著，可作为加权就业规模下降的辅助证据。	PPML 与分数 Logit 一致，未发现显著下降。
DML	若不同学习器下处理效应均为负且显著，可解释为控制可观测特征后的收入负向关联。	Lasso-DML 为负向边际信号，GBRT-DML 不稳健，因此只称为早期弱信号。
RIF 分位数	若多个分位点方向一致且显著，可说明收入分布发生系统性变化。	第 75 分位附近存在边际负向信号，但整体不稳定，不宣称分布效应。

8.2 稳健性设计与尚未完全解决的问题

本文已经完成的稳健性包括四类。第一，暴露度口径替换：连续基期暴露度、高暴露四分位和 K-means 类型之间相互复核。第二，模型口径替换：就业结构使用分数 Logit 和 PPML，收入结果使用 DML 和 RIF。第三，样本口径审查：区分职业-年份面板和个体收入样本，避免用同一套样本解释所有问题。第四，映射质量审查：记录 ISCO-SOC 映射层级，并在解释中说明多对多映射带来的不确定性。

仍需在未来研究中进一步解决的问题包括：其一，CGSS 年份较少，无法形成强事件研究设计；其二，2023 年调查中的收入更接近 2022 年收入，难以捕捉 GPT 后完整调整；其三，职业映射会削弱个体层面暴露度度量的精度；其四，缺少企业层面 AI 采用信息，因此不能区分“职业任务可被 AI 影响”和“劳动者所在岗位真实采用 AI”。这些限制不会否定本文的探索价值，但要求最终结论以“暴露度与劳动市场结果的早期关联”为主，而不是直接使用强因果表述。

参考文献

[1] Ronald A. Fisher. *Statistical Methods for Research Workers*. Oliver and Boyd, 1925.

- [2] Jeffrey M. Wooldridge. *Econometric Analysis of Cross Section and Panel Data*. 2nd ed. MIT Press, 2010.
- [3] James MacQueen. “Some Methods for Classification and Analysis of Multivariate Observations”. In: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. 1967, pp. 281–297.
- [4] Leslie E. Papke and Jeffrey M. Wooldridge. “Econometric Methods for Fractional Response Variables with an Application to 401(k) Plan Participation Rates”. In: *Journal of Applied Econometrics* 11.6 (1996), pp. 619–632. DOI: [10.1002/\(SICI\)1099-1255\(199611\)11:6<619::AID-JAE418>3.0.CO;2-1](https://doi.org/10.1002/(SICI)1099-1255(199611)11:6<619::AID-JAE418>3.0.CO;2-1).
- [5] J. M. C. Santos Silva and Silvana Tenreyro. “The Log of Gravity”. In: *The Review of Economics and Statistics* 88.4 (2006), pp. 641–658. DOI: [10.1162/rest.88.4.641](https://doi.org/10.1162/rest.88.4.641).
- [6] Victor Chernozhukov et al. “Double/Debiased Machine Learning for Treatment and Structural Parameters”. In: *The Econometrics Journal* 21.1 (2018), pp. C1–C68. DOI: [10.1111/ectj.12097](https://doi.org/10.1111/ectj.12097).
- [7] Sergio Firpo, Nicole M. Fortin, and Thomas Lemieux. “Unconditional Quantile Regressions”. In: *Econometrica* 77.3 (2009), pp. 953–973. DOI: [10.3982/ECTA6822](https://doi.org/10.3982/ECTA6822).